Clase 10 Pruebas no paramétricas

Curso Introducción al Análisis de datos con R para la acuicultura.

Dr. José A. Gallardo | jose.gallardo@pucv.cl | Pontificia Universidad Católica de Valparaíso

20 July 2021

PLAN DE LA CLASE

1.- Introducción

- ¿Qué son las pruebas no paramétricas?.
- Test de Correlación no paramétrico.
- Pruebas de contraste no paramétrico.
- Prueba de asociación Chi cuadrado.

2.- Práctica con R y Rstudio cloud

- Realizar pruebas no paramétricas.
- Realizar gráficas avanzadas con ggplot2.
- Elaborar un reporte dinámico en formato pdf.

MÉTODOS NO PARAMÉTRICOS

Conjunto diverso de pruebas estadísticas.

El concepto de “no paramétrico” a veces es confuso, pues los métodos no paramétricos si estiman y someten a prueban hipótesis usando parámetros, pero no los de distribución normal.

Se aplican usualmente para variables cuantitativas que no cumplen con el supuesto de normalidad y para variables cualitativas.

SUPUESTOS: MÉTODOS NO PARAMÉTRICOS

El principal supuesto de los métodos no paramétricos es que las variables aleatorias son independientes y con identica distribución.

Usualmente no tienen supuestos acerca de la distribución de la variable, alternativamente se conocen como métodos de distribución libre.

El concepto matemático de permutación está subyacente a muchos métodos no paramétricos y se utiliza para someter a prueba una hipótesis.

PRUEBA DE CORRELACIÓN NO PARAMÉTRICA

¿Para que sirve?

Para estudiar asociación de dos variables, cuando no se cumple uno o varios supuestos de la correlación paramétrica:

- Las variables X e Y no son continuas.
- No existe relación lineal.
- La distribución conjunta de (X, Y) no es una distribución Bivariable normal.

EJEMPLO FUNCIÓN MONÓTONA

¿Cuál es el supuesto que no se cumple?

No existe una relación lineal

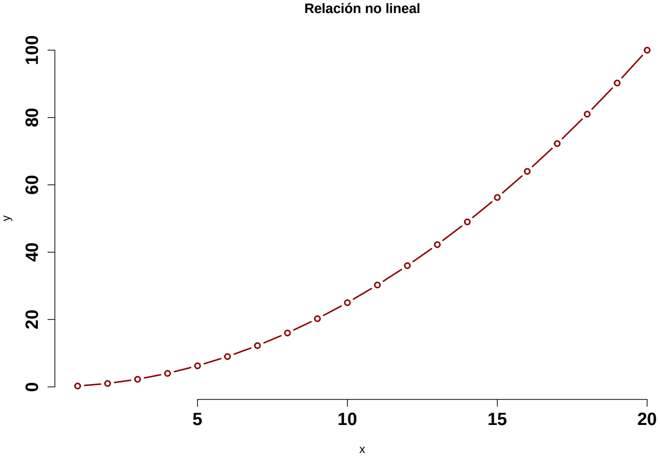

EJEMPLO VARIABLES DISCRETAS U ORDINALES

¿Cuál es el supuesto que no se cumple?

Parásitos es variable discreta.

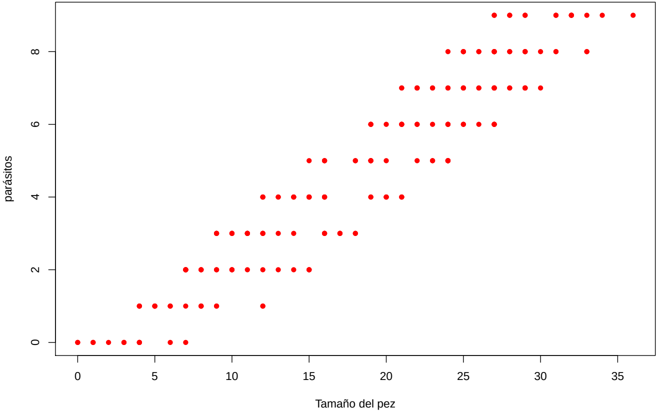

EJEMPLO VARIABLES DISCRETAS U ORDINALES 2

¿Cuál es el supuesto que no se cumple?

Parásitos no tiene distribución normal

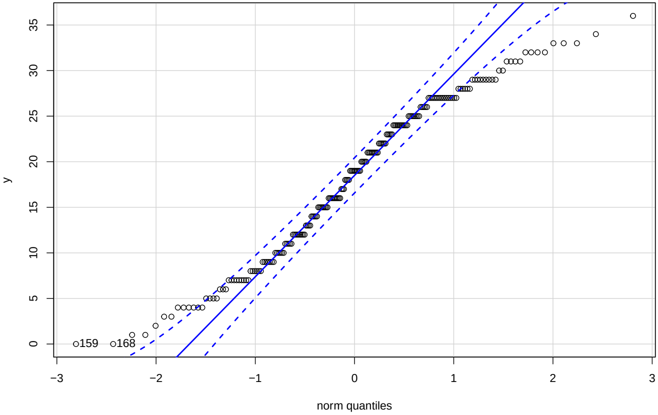


```
## [1] 159 168
```

COEFICIENTE DE CORRELACIÓN DE SPEARMAN

¿Cómo se calcula?

Coeficiente de correlación de Spearman (ρ = rho)

$$\rho = 1 - \frac{6 \sum d^2}{n(n^2 - 1)} = -0,6$$

Fish size (X)	**Parásitos (Y)**	**Ranking X**	**Ranking Y**	d	d^2
942	13	4	2	2	4
101	14	1	3	-2	4
313	18	2	4	-2	4
800	10	3	1	2	4

$$\sum d^2 = 16$$

¿CUÁNTAS CORRELACIONES SON POSIBLES?

Ejemplo correlación -1 Y 1

Ranking X	**Ranking Y**	**Ranking X**	**Ranking Y**
4	1	4	4
1	4	1	1
2	3	2	2
3	2	3	3
$\rho =$ -1			$\rho = 1$

DISTRIBUCIÓN MUESTRAL DE CORRELACIÓN

Permutación: combinación ordenada de elementos.

P4 = 4! = 4 x 3 x 2 x 1 = 24 permutaciones posibles.

¿Cuántas combinaciones son mayores o igual a nuestros datos?

-1.0, -0.8, -0.8, -0.8, -0.6, -0.4, -0.4, -0.4, -0.4, -0.2, -0.2, 0.0, 0.0, 0.2, 0.2, 0.4, 0.4, 0.4, 0.4, **0.6, 0.8, 0.8, 0.8, 1.0**

PRUEBA DE HIPÓTESIS DE CORRELACIÓN

Hipótesis	**Verdadera cuando**
$\mathbf{H_0}$: X e Y mutuamente independientes	$\rho = 0$
$\mathbf{H_1}$: X e Y no son mutuamente independientes	$\rho \neq 0$

p = 10 / 24 p = 0.4167

No se rechaza $\mathbf{H_0}$ porque p = 0,416 es mayor a 0,05

PRUEBA DE CORRELACIÓN CON R

```r
# Crea objetos X e Y
X <- c(942,101,313,800)
Y <- c(13,14,18,10)

# Realiza test de correlación
cor.test(X,Y, method = "spearman",
         alternative = "two.sided")
```

```
##
##  Spearman's rank correlation rho
##
## data:  X and Y
## S = 16, p-value = 0.4167
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##  rho
## -0.6
```

COMPARACIÓN DE MUESTRAS INDEPENDIENTES

¿Para qué sirve?
Para comparar dos muestras con idéntica distribución, con diferentes medianas y sin normalidad.

Usualmente para variables discretas.

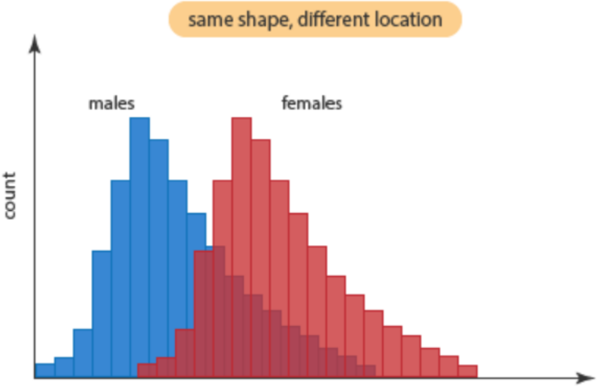

CÁCULO DE ESTADÍSTICO MANN-WHITNEY (W)

¿Cómo se calcula el estadístico W?
Como la diferencia de los ranking entre tratamiento y control

Tratamiento (T)	**Control (C)**	**Ranking T**	**Ranking C**
9	0	4	1
12	4	5	2
13	6	6	3
		$\sum = 15$	$\sum = 6$

$W = 15 - 6 = 9$
Máxima diferencia posible entre T y C.

DISTRIBUCIÓN MUESTRAL DE W

¿Cuántas combinaciones son posibles?

6! / 3! X 3! = 720 / 36 = 20

3 resultados posibles de 20

T	**C**	**T**	**C**	**T**	**C**
1	4	1	2	2	1
2	5	4	3	5	3
3	6	5	6	6	4
6	*15*	*10*	*11*	*13*	*8*
$W =$	- **9**	$W =$	- **1**	$W =$	**5**

PRUEBA DE HIPÓTESIS DE MANN-WHITNEY

Hipótesis
$\mathbf{H_0}$: Tratamiento $=$ Control
$\mathbf{H_1}$: Tratamiento $>$ Control

Resultado obtenido W=9.
$p = 1/20$
$p = 0.05$

No se rechaza $\mathbf{H_0}$ porque $p = 0{,}05$

PRUEBA DE MANN-WHITNEY CON R

```r
# Crea objetos tratamiento y control
t <- c(9, 12, 13)
c <- c(0, 4, 6)

# Realiza prueba de Mann-Whitney
wilcox.test(t, c, alternative = "g",
            paired = FALSE)
```

```
##
##  Wilcoxon rank sum test
##
## data:  t and c
## W = 9, p-value = 0.05
## alternative hypothesis: true location shift is greater t
```

COMPARACIÓN DE MUESTRAS PAREADAS

¿Para que sirve?
Para comparar dos muestras *pareadas* con idéntica distribución, con diferentes medianas y sin normalidad.

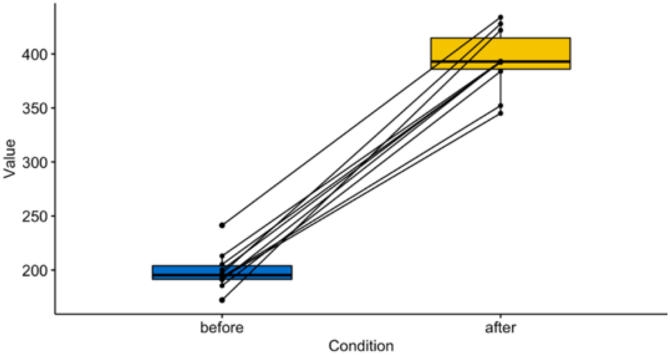

PRUEBA DE WILCOXON MUESTRAS PAREADAS

Estudio de caso: Gonadotrofina en trucha 7 y 14 días **post ovulación**

Trucha	**7 días**	**14 días**	d	Ranking con signo
1	45	49	4	**2**
2	41	50	9	**4**
3	47	52	5	**3**
4	52	50	2	**-1**

Hipótesis
$\mathbf{H_0}$: d $= 0$
$\mathbf{H_1}$: d > 0

DISTRIBUCIÓN MUESTRAL DE W

¿Cuántas combinaciones de signos (+ o -) son posibles?

$$2^4 = 16$$

¿Cuántas combinaciones son mayores o igual a nuestros datos?
-10, -8, -6, -4, -4, -2, -2, 0, 0, 2, 2, 4, 4, 6, **8**, **10**

p = 2/16
p = 0,125

No se rechaza $\mathbf{H_0}$ porque p = 0,125 es mayor a 0,05

PRUEBA DE WILCOXON PAREADAS CON R

```r
# Crea objetos pre y post
pre <- c(45, 41, 47, 52)
post <- c(49, 50, 52, 50)
# Realiza prueba de Wilcoxon
wilcox.test(post - pre, alternative = "greater")
```

```
##
##  Wilcoxon signed rank test
##
## data:  post - pre
## V = 9, p-value = 0.125
## alternative hypothesis: true location is greater than 0
```

```r
# no es necesario indicar muestras pareadas
# pues estamos haciendo la resta en la función.
```

COMPARACIÓN DE MÚLTIPLES MUESTRAS INDEPENDIENTES

¿Para que sirve?
Para comparar múltiples muestras con idéntica distribución, con diferentes medianas y sin normalidad.

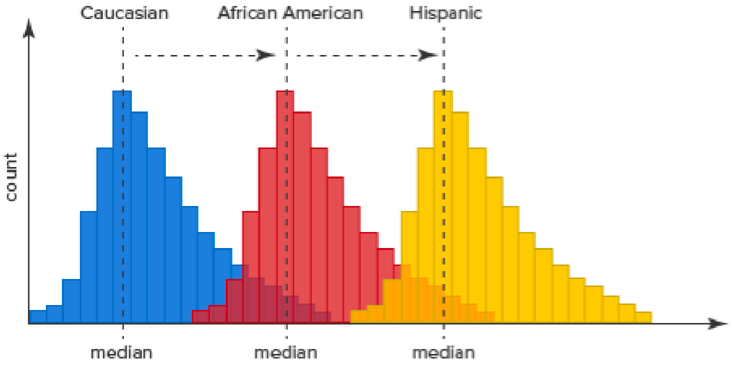

ESTUDIO DE CASO: SCORE CALIDAD CAMARÓN

Score de calidad organoléptica (textura) de camarón **link**.

Descripción	Puntaje
Muy compacto y denso	9
Menos elástico, compacto y denso	7
No elástico, no compacto y no denso	5
Ligeramente blando	3
Suave	1

PRUEBA DE KRUSKAL - WALLIS

Textura luego de 0, 4 y 8 días de almacenamiento de camarón congelado.

0 días	**4 días**	**8 días**
9	7	6
8	7	5
9	6	5
8	8	6

Hipótesis
$\mathbf{H_0}$: La distribución de los k grupos son iguales.
$\mathbf{H_1}$: Al menos 2 grupos son distintos.

PRUEBA DE KRUSKAL - WALLIS CON R

```r
d0 <- c(9,8,9,8) # day0
d4 <- c(7,7,6,8) # day4
d8 <- c(6,5,5,6) # day8
kruskal.test(list(d0, d4, d8))
```

```
##
##  Kruskal-Wallis rank sum test
##
## data:  list(d0, d4, d8)
## Kruskal-Wallis chi-squared = 9, df = 2, p-value = 0.0111
```

PRUEBA DE ASOCIACIÓN VARIABLES CATEGÓRICAS

¿Para que sirve?
Se utilizan para investigar la asociación de dos o más variables categóricas una de las cuales es una variable respuesta y la otra es una variable predictora.

Tratamiento	Respuesta +	Respuesta -
Si	a	c
No	b	d

PRUEBA DE CHI CUADRADO

Esta prueba contrasta frecuencias observadas con las frecuencias esperadas de acuerdo con la hipótesis nula.

Hipótesis
$\mathbf{H_0}$: La variable predictora y la variable respuesta son independientes (Tratamiento = control)
$\mathbf{H_1}$: La variable predictora y la variable respuesta NO son independientes

Supuestos:

- Los datos provienen de una muestra aleatoria de la población de interés.
- El tamaño de muestra es lo suficientemente grande para que el número esperado en las categorías sea mayor 5 y que ninguna frecuencia sea menor que 1.

ESTUDIO DE CASO: SOBREVIVENCIA MANCHA BLANCA CAMARÓN

Sobrevivencia de postlarvas alimentadas con B glucanos y desafiadas con WSSP **link**.

Tratamiento	**Sobrevivientes**	**Muertos**
Con glucanos	20	80
Sin glucanos	5	95

CÁLCULO DE ESTADÍSTICO CHI CUADRADO

¿Cómo se calcula el estadístico Chi cuadrado?

$$X^2 = \sum \frac{(freq.obs. - freq.esp.)^2}{(freq.esperada)} = \sum \frac{(O - E)^2}{(E)}$$

Frecuencia esperada

```
##      [,1] [,2]
## [1,] 12.5 87.5
## [2,] 12.5 87.5
```

```
## X-squared
##  10.28571
```

PRUEBA DE CHI CUADRADO CON R

```r
# Crea matriz de datos
datos <- c(20, 5, 80, 95)
dim(datos) <- c(2,2)
# Test de Chi-squared en R (chisq.test)
chisq.test(datos, correct = FALSE)
```

```
##
##  Pearson's Chi-squared test
##
## data:  datos
## X-squared = 10.286, df = 1, p-value = 0.001341
```

PRÁCTICA ANÁLISIS DE DATOS

- Guía de trabajo práctico disponible en drive y Rstudio.cloud.
  Clase_10
- El trabajo práctico se realiza en Rstudio.cloud.
  Clase 10 - Estadística no paramétrica

RESUMEN DE LA CLASE

Revisión de conceptos de estadística no paramétrica.

- Correlación de Spearman.
- Prueba de Man-Whitney.
- Prueba de Wilcoxon.
- Prueba de Kruskal Wallis.
- Prueba de Chi-cuadrado.