

Clase 10 Pruebas no paramétricas

Curso Introducción al Análisis de datos con R para la
acuicultura.

Dr. José A. Gallardo | jose.gallardo@pucv.cl | Pontificia
Universidad Católica de Valparaíso

20 July 2021

PLAN DE LA CLASE

1.- Introducción

- ▶ ¿Qué son las pruebas no paramétricas?.
- ▶ Test de Correlación no paramétrico.
- ▶ Pruebas de contraste no paramétrico.
- ▶ Prueba de asociación Chi cuadrado.

2.- Práctica con R y Rstudio cloud

- ▶ Realizar pruebas no paramétricas.
- ▶ Realizar gráficas avanzadas con ggplot2.
- ▶ Elaborar un reporte dinámico en formato pdf.

MÉTODOS NO PARAMÉTRICOS

Conjunto diverso de pruebas estadísticas.

El concepto de “no paramétrico” a veces es confuso, pues los métodos no paramétricos si estiman y someten a prueban hipótesis usando parámetros, pero no los de distribución normal.

Se aplican usualmente para variables cuantitativas que no cumplen con el supuesto de normalidad y para variables cualitativas.

SUPUESTOS: MÉTODOS NO PARAMÉTRICOS

El principal supuesto de los métodos no paramétricos es que las variables aleatorias son independientes y con idéntica distribución.

Usualmente no tienen supuestos acerca de la distribución de la variable, alternativamente se conocen como métodos de distribución libre.

El concepto matemático de permutación está subyacente a muchos métodos no paramétricos y se utiliza para someter a prueba una hipótesis.

PRUEBA DE CORRELACIÓN NO PARAMÉTRICA

¿Para que sirve?

Para estudiar asociación de dos variables, cuando no se cumple uno o varios supuestos de la correlación paramétrica:


- Las variables X e Y no son continuas.
- No existe relación lineal.
- La distribución conjunta de (X, Y) no es una distribución Bivariable normal.

EJEMPLO FUNCIÓN MONÓTONA

¿Cuál es el supuesto que no se cumple?

No existe una relación lineal


Relación no lineal



EJEMPLO VARIABLES DISCRETAS U ORDINALES

¿Cuál es el supuesto que no se cumple?


Parásitos es variable discreta.



EJEMPLO VARIABLES DISCRETAS U ORDINALES 2

¿Cuál es el supuesto que no se cumple?

Parásitos no tiene distribución normal



[1] 159 168

COEFICIENTE DE CORRELACIÓN DE SPEARMAN

¿Cómo se calcula?

Coeficiente de correlación de Spearman ($\rho = \text{rho}$)

$$\rho = 1 - \frac{6 \sum d^2}{n(n^2 - 1)} = -0,6$$

Fish size (X)	Parásitos (Y)	Ranking X	Ranking Y	d	d ²
942	13	4	2	2	4
101	14	1	3	-2	4
313	18	2	4	-2	4
800	10	3	1	2	4

$$\sum d^2 = 16$$

¿CUÁNTAS CORRELACIONES SON POSIBLES?

Ejemplo correlación -1 Y 1

Ranking X	Ranking Y	Ranking X	Ranking Y
4	1	4	4
1	4	1	1
2	3	2	2
3	2	3	3
$\rho = -1$			$\rho = 1$

DISTRIBUCIÓN MUESTRAL DE CORRELACIÓN

Permutación: combinación ordenada de elementos.

$P_4 = 4! = 4 \times 3 \times 2 \times 1 = 24$ permutaciones posibles.

¿Cuántas combinaciones son mayores o igual a nuestros datos?

-1.0, -0.8, -0.8, -0.8, -0.6, -0.4, -0.4, -0.4, -0.4, -0.2, -0.2, 0.0,
0.0, 0.2, 0.2, 0.4, 0.4, 0.4, 0.4, **0.6, 0.8, 0.8, 0.8, 1.0**

PRUEBA DE HIPÓTESIS DE CORRELACIÓN

Hipótesis	Verdadera cuando
H_0 : X e Y mutuamente independientes	$\rho = 0$
H_1 : X e Y no son mutuamente independientes	$\rho \neq 0$

$$p = 10 / 24 \quad p = 0.4167$$

No se rechaza H_0 porque $p = 0,416$ es mayor a $0,05$

PRUEBA DE CORRELACIÓN CON R

```
# Crea objetos X e Y
```

```
X <- c(942,101,313,800)
```

```
Y <- c(13,14,18,10)
```

```
# Realiza test de correlación
```

```
cor.test(X,Y, method = "spearman",  
          alternative = "two.sided")
```

```
##
```

```
## Spearman's rank correlation rho
```

```
##
```

```
## data: X and Y
```

```
## S = 16, p-value = 0.4167
```

```
## alternative hypothesis: true rho is not equal to 0
```

```
## sample estimates:
```

```
## rho
```


```
## -0.6
```

COMPARACIÓN DE MUESTRAS INDEPENDIENTES

¿Para qué sirve?

Para comparar dos muestras con idéntica distribución, con diferentes medianas y sin normalidad.

Usualmente para variables discretas.



PRUEBA DE MANN-WHITNEY (W)

Estudio de caso: Conducta agresiva (minutos de pelea) entre tilapias cultivadas en estanque mosexo (Tratamiento: solo machos) y estanques mixtos (Control: Machos y hembras) **Link**

Tratamiento (T)	Control (C)
9	0
12	4
13	6

CÁLCULO DE ESTADÍSTICO MANN-WHITNEY (W)

¿Cómo se calcula el estadístico W?

Como la diferencia de los ranking entre tratamiento y control

Tratamiento (T)	Control (C)	Ranking T	Ranking C
9	0	4	1
12	4	5	2
13	6	6	3
		$\Sigma = 15$	$\Sigma = 6$

$$W = 15 - 6 = 9$$

Máxima diferencia posible entre T y C.

DISTRIBUCIÓN MUESTRAL DE W

¿Cuántas combinaciones son posibles?

$$6! / 3! \times 3! = 720 / 36 = 20$$

3 resultados posibles de 20

T	C	T	C	T	C
1	4	1	2	2	1
2	5	4	3	5	3
3	6	5	6	6	4
<i>6</i>	<i>15</i>	<i>10</i>	<i>11</i>	<i>13</i>	<i>8</i>
<i>W =</i>	- 9	<i>W =</i>	- 1	<i>W =</i>	5

PRUEBA DE HIPÓTESIS DE MANN-WHITNEY

Hipótesis

H₀: Tratamiento = Control

H₁: Tratamiento > Control

Resultado obtenido $W=9$.

$$p = 1/20$$

$$p = 0.05$$

No se rechaza **H₀** porque $p = 0,05$

PRUEBA DE MANN-WHITNEY CON R

```
# Crea objetos tratamiento y control
```

```
t <- c(9, 12, 13)
```

```
c <- c(0, 4, 6)
```

```
# Realiza prueba de Mann-Whitney
```

```
wilcox.test(t, c, alternative = "g",  
            paired = FALSE)
```

```
##
```

```
## Wilcoxon rank sum test
```

```
##
```

```
## data: t and c
```


```
## W = 9, p-value = 0.05
```

```
## alternative hypothesis: true location shift is greater t
```

COMPARACIÓN DE MUESTRAS PAREADAS

¿Para que sirve?

Para comparar dos muestras *pareadas* con idéntica distribución, con diferentes medianas y sin normalidad.



PRUEBA DE WILCOXON MUESTRAS PAREADAS

Estudio de caso: Gonadotrofina en trucha 7 y 14 días **post ovulación**

Trucha	7 días	14 días	d	Ranking con signo
1	45	49	4	2
2	41	50	9	4
3	47	52	5	3
4	52	50	2	-1

Hipótesis

H_0 : $d = 0$

H_1 : $d > 0$

DISTRIBUCIÓN MUESTRAL DE W

¿Cuántas combinaciones de signos (+ o -) son posibles?

$$2^4 = 16$$

¿Cuántas combinaciones son mayores o igual a nuestros datos?

-10, -8, -6, -4, -4, -2, -2, 0, 0, 2, 2, 4, 4, 6, **8, 10**

$$p = 2/16$$

$$p = 0,125$$

No se rechaza **H₀** porque $p = 0,125$ es mayor a 0,05

PRUEBA DE WILCOXON PAREADAS CON R

```
# Crea objetos pre y post  
pre <- c(45, 41, 47, 52)  
post <- c(49, 50, 52, 50)  
# Realiza prueba de Wilcoxon  
wilcox.test(post - pre, alternative = "greater")
```


```
##  
## Wilcoxon signed rank test  
##  
## data: post - pre  
## V = 9, p-value = 0.125  
## alternative hypothesis: true location is greater than 0
```

```
# no es necesario indicar muestras pareadas  
# pues estamos haciendo la resta en la función.
```

COMPARACIÓN DE MÚLTIPLES MUESTRAS INDEPENDIENTES

¿Para que sirve?

Para comparar múltiples muestras con idéntica distribución, con diferentes medianas y sin normalidad.



ESTUDIO DE CASO: SCORE CALIDAD CAMARÓN

Score de calidad organoléptica (textura) de camarón **link**.

Descripción	Puntaje
Muy compacto y denso	9
Menos elástico, compacto y denso	7
No elástico, no compacto y no denso	5
Ligeramente blando	3
Suave	1

PRUEBA DE KRUSKAL - WALLIS

Textura luego de 0, 4 y 8 días de almacenamiento de camarón congelado.

0 días	4 días	8 días
9	7	6
8	7	5
9	6	5
8	8	6

Hipótesis

H₀: La distribución de los k grupos son iguales.

H₁: Al menos 2 grupos son distintos.

PRUEBA DE KRUSKAL - WALLIS CON R

```
d0 <- c(9,8,9,8) # day0  
d4 <- c(7,7,6,8) # day4  
d8 <- c(6,5,5,6) # day8  
kruskal.test(list(d0, d4, d8))
```

```
##
```

```
##  Kruskal-Wallis rank sum test
```

```
##
```

```
## data:  list(d0, d4, d8)
```

```
## Kruskal-Wallis chi-squared = 9, df = 2, p-value = 0.0111
```

PRUEBA DE ASOCIACIÓN VARIABLES CATEGÓRICAS

¿Para que sirve?

Se utilizan para investigar la asociación de dos o más variables categóricas una de las cuales es una variable respuesta y la otra es una variable predictora.

Tratamiento	Respuesta +	Respuesta -
Si	a	c
No	b	d

PRUEBA DE CHI CUADRADO

Esta prueba contrasta frecuencias observadas con las frecuencias esperadas de acuerdo con la hipótesis nula.

Hipótesis

H₀: La variable predictora y la variable respuesta son independientes (Tratamiento = control)

H₁: La variable predictora y la variable respuesta NO son independientes

Supuestos:

- Los datos provienen de una muestra aleatoria de la población de interés.
- El tamaño de muestra es lo suficientemente grande para que el número esperado en las categorías sea mayor 5 y que ninguna frecuencia sea menor que 1.

ESTUDIO DE CASO: SOBREVIVENCIA MANCHA BLANCA CAMARÓN

Sobrevivencia de postlarvas alimentadas con *B* glucanos y desafiadas con WSSP **link**.

Tratamiento	Sobrevivientes	Muertos
Con glucanos	20	80
Sin glucanos	5	95

CÁLCULO DE ESTADÍSTICO CHI CUADRADO

¿Cómo se calcula el estadístico Chi cuadrado?

$$\chi^2 = \sum \frac{(\text{freq.obs.} - \text{freq.esp.})^2}{(\text{freq.esperada})} = \sum \frac{(O - E)^2}{(E)}$$

Frecuencia esperada

```
##      [,1] [,2]  
## [1,] 12.5 87.5  
## [2,] 12.5 87.5
```

```
## X-squared  
##  10.28571
```

PRUEBA DE CHI CUADRADO CON R

```
# Crea matriz de datos  
datos <- c(20, 5, 80, 95)  
dim(datos) <- c(2,2)  
# Test de Chi-squared en R (chisq.test)  
chisq.test(datos, correct = FALSE)
```

```
##  
##  Pearson's Chi-squared test  
##  
## data:  datos  
## X-squared = 10.286, df = 1, p-value = 0.001341
```


PRÁCTICA ANÁLISIS DE DATOS

- ▶ Guía de trabajo práctico disponible en drive y Rstudio.cloud.

Clase_10

- ▶ El trabajo práctico se realiza en Rstudio.cloud.

Clase 10 - Estadística no paramétrica

RESUMEN DE LA CLASE

Revisión de conceptos de estadística no paramétrica.

- ▶ Correlación de Spearman.
- ▶ Prueba de Man-Whitney.
- ▶ Prueba de Wilcoxon.
- ▶ Prueba de Kruskal Wallis.
- ▶ Prueba de Chi-cuadrado.